

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1935

Lokalizacija autonomnog vozila u simuliranom urbanom okruženju

Matija Vukić

Zagreb, srpanj 2019.

Zagreb, 14. ožujka 2019.

DIPLOMSKI ZADATAK br. 1935

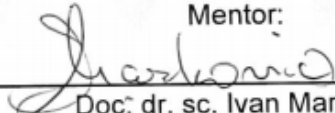
Pristupnik: **Matija Vukić (0036481300)**
Studij: Računarstvo
Profil: Programsko inženjerstvo i informacijski sustavi

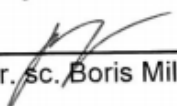
Zadatak: **Lokalizacija autonomnog vozila u simuliranom urbanom okruženju**

Opis zadatka:

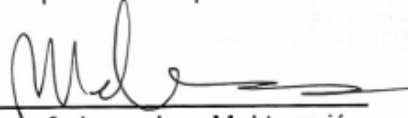
Lokalizacija, odnosno poznavanja vlastitog položaja u prostoru, jedan je od osnovnih algoritama autonomnih vozila. Testiranje i evaluacija algoritama lokalizacije autonomnih vozila zahtjevan je problem zbog izazova prikupljanja referentnih podataka u urbanim okruženjima. Jedno je rješenje za navedeni problem korištenje računalnih simulacija, koje danas mogu vjerno modelirati realne senzore i okruženja te predstavljaju učinkovito rješenje za snimanje referentnih podataka kao i smanjenje vremena testiranja. U diplomskom je zadatku potrebno testirati algoritme lokalizacije autonomnih vozila koristeći simuliranu urbanu okolinu. Pomoću generiranih podataka senzora autonomnog vozila, potrebno je estimirati položaj vozila u odnosu na globalnu kartu simuliranog okruženja. Po mogućnosti, potrebno je razmotriti i fuziju podataka iz različitih senzora

Zadatak uručen pristupniku: 15. ožujka 2019.
Rok za predaju rada: 28. lipnja 2019.

Mentor:

Doc. dr. sc. Ivan Marković

Djelovođa:

Izv. prof. dr. sc. Boris Milašinović

Predsjednik odbora za
diplomski rad profila:


Izv. prof. dr. sc. Igor Mekterović

Zahvala mentoru Doc. Dr. Sc. Ivanu Markoviću za strpljenje i vodstvu

SADRŽAJ

1. Uvod	1
2. Problem lokalizacije vozila	2
2.1. Lokalizacija	2
2.2. Problem lokalizacije	4
3. Priprema podataka	5
3.1. Simulator	5
3.2. Opis okruženja	8
3.3. Oblak točaka	12
3.4. Referentni podaci	14
3.5. Izvor podataka	17
3.6. Prikupljanje podataka	20
4. Algoritmi lokalizacije	29
4.1. Obitelj algoritama	29
4.2. Dijeljeni kod i ulazni podaci	32
5. Algoritmi	44
5.1. Generalizirani ICP algoritam	44
5.2. ICP algoritam s grupiranjem točaka	46
6. Eksperimentalni rezultati	48
6.1. Generalizirani ICP algoritam	48
6.2. ICP algoritam s grupiranjem točaka	55
7. Zaključak	60
Literatura	61

1. Uvod

U zadnjih 30ak godina se može vidjeti ubrzan napredak u automatici i računarstvu. Tome su prethodile godine teoretskog razvoja iz kojih su kasnije nastali razni algoritmi za optimizacije i obradu podataka. Sada s razvojem računalnih komponenata poput memorija te procesorske snage možemo obrađivati sve više podataka u manje vremena. To omogućuje današnjim vozilima da u potpunosti budu električna što znači da su stalno u kontaktu s okolinom te mogu bez prestanka skupljati podatke iz okoline. Ta vozila su zapravo skupine senzora i urađaja konstantno povezanih na internet.

Skoro sva takva vozila danas imaju mogućnost autonomne vožnje. To omogućuju ljudima ugodnije iskustvo te veliko smanjenje broja prometnih nesreća koje uzrokuju vozači u stanjima koja nisu prigodna za vožnju ili čistome nemaru. S obzirom da je sigurnost u prometu jedna od najvažnijih stvari po pitanju svih sudionika, ona mora biti prioritet. To znači da svi algoritmi za bilo kavo upravljanje vozilom moraju biti u potpunosti testirani te bez ikakvih pograšaka. Naravno to je nemoguć zahtjev zato što u takvoj domeni ti algoritmi za rad imaju previše varijabli koje se ne mogu uzeti u obzir.

Cilj ovoga rada je objasniti i prikazati rezultate nekoliko algoritama te njihove točnosti. Ulaz u algoritam su senzorska očitavanja dok su izlazi lokacija vozila tj. relativna promjena lokacije između dva očitavanja. Za usporedbu rezultata koristimo referentne podatke koji su prikupljeni iz simulatora te je tako garantirana njihova točnost. Nekoliko primjera podataka je provedeno kroz algoritme te uspoređeno s referentnim podacima.

2. Problem lokalizacije vozila

2.1. Lokalizacija

Roboti i vozila u većini slučajeva se primjenjuju za izvođenje repetitivnih ili opasnih po život poslova. Čovjeka zamjenjuje robot ali to znači da je za upravljanje robota zadužen taj isti robot ili neki udaljeni sustav, čovjek više nema tu ulogu. U tu svrhu su roboti i vozila opremljeni raznim senzorima da bi se to omogućilo. Svi podaci prikupljeni iz tih senzora se koriste prilikom lokalizacije robota ili vozila.

Lokalizacija je postupak određivanja lokacije objekta u prostoru iz senzorskih podataka. Lokalizacija može biti vrlo zahtjevan zadatak te se u tu svrhu mogu koristiti algoritmi različitih složenosti. Što je algoritam složeniji, to se sporije izvodi ali je točniji dok se neki više optimizirani tj. brži algoritmi brže izvode ali se događaju veće greške te se one akumuliraju prilikom izvođenja algoritma.

Koriste se algoritmi za istovremenu lokalizaciju i mapiranje [?] tj. za stvaranje karte nepoznatog prostora kojime se robot kreće te koordinate u tome prostoru. Lokalizacija odgovara 'Gdje je robot sada?' tj. gdje je sada naspram prethodne lokacije. Na to pitanje se može odgovoriti ovisno o tome radi li se o lokalizaciji u otvorenome ili zatvorenome prostoru. Lokacija robota je uglavnom prikazana u kartezijском koordinatnom sustavu, bilo to u 2d ili 3d prostoru.

Postoje dvije vrste lokalizacije:

- Lokalna - informacije se prikupljaju pomoću senzora robota iz njegove okoline
- Globalna - informacije se dobiju iz GPS-a ili slično

Pregled pristupa problemu lokalizacije

Jedna od najjednostavnijih metoda je "Metoda najmanjih kvadrata" (eng. Least Squares Error) gdje se koristi metoda najmanjih kvadrata za regresijsku analizu podataka. Cilj te metode jest minimizacija pogreške gdje robot jest i gdje bi robot trebao biti tj. ona okvirno procjenjuje gradijent funkcije pomaka robota.

Praćenje pozicije (eng. Pose Tracking) metoda se koristi kada je poznata početna pozicija robota pa je potrebno samo pratiti njegovu poziciju kroz vrijeme. Metoda koristi ekstrakciju tj. izdvajanje značajki okoline koje se mogu uspoređivati te se tako kroz vrijeme može pratiti promjena položaja nekih uočljivih objekata.

Metoda višestrukih hipoteza (eng. Multiple Hypothesis Localization) pretpostavlja da početna pozicija nije poznata ali je poznata topografija mape. U ovome slučaju početnu poziciju može robotu pridodati korisnik ili robot uvijek može započeti iz iste pozicije. Ideja iza ove metode je da se detektira svojstvo te se preko njega stvaraju hipoteze o položaju robota naspram toga objekta kojemu pripada to svojstvo. Može se stvoriti nova hipoteza ili se može poboljšati neka od prethodnih hipoteza ili ipak eliminirati.

Metoda iteracije najbližih točaka (eng. Iterative Closest Point) minimizira razliku između dvije skupine točaka tako da iterira između svake dvije točke te pronalazi onu kombinaciju koja daje najmanju grešku. Često se koristi pri rekonstrukciji 2D ili 3D površina nakon skeniranja. Tijekom izvođenja te metode jedna skupina točaka je fiksna tj. referentna dok se druga transformira tako da se najbolje slažu koordinatama u referentnom skupu. Postoje mnoge varijante ICP-a od kojih su point-to-point (usporedba točka-točka) , point-to-plane (usporedba točke-površina) i point-to-line (usporedba točka-linija) najpopularnije.

Metoda usporedbe očitavanja (eng. scan matching) koristi dva uzastopna očitavanja senzora robota poput lasera, sonara, ... da se pronađe relativan pomak robota u prostoru. Razlike između dva očitavanja senzora se mogu uočiti vrlo lako zbog učestalosti skeniranja tj. frekvencije dohvaćanja senzorskih podataka te o gustoći lasera kojih uglavnom ima od nekoliko stotina do nekoliko tisuća. Načina na koji se zapravo traže razlike između dva očitavanja ima mnogo. Koriste se laseri (eng. laser range finders) da bi vidio prepreke i odometrija kotača (eng. wheel odometry) da dobije okvirno stanje robota. Odometrija iz kotača ima određenu grešku zbog proklizavanja kotača ili nekog drugog razloga te se ona tada ispravlja pomoću izračunatih vrijednosti odometrije iz lasera. Ova metoda je zapravo metoda iteracije najbližih točaka ali ograničena u dvije dimenzije.

2.2. Problem lokalizacije

Sve prethodno navedene imaju nešto zajedničko, a to je da koriste algoritme čiji rezultati nikada nisu posve točni.

Ta netočnost može proizaći zbog sljedećih razloga:

- Šum u očitanjima - u podacima koji se dobiju iz senzora uvijek ima i podataka koji su nastali zbog privremenih objekata (npr. pas koji prolazi pokraj vozila)
- Sinkronizacija obrade i očitavanja podataka - zbog prebrzog slanja podataka algoritmu, te se tako mogu neka očitavanja preskočiti
- Samog načina izvedbe senzora - možda senzor zbog samog načina fizičke izvedbe ima uračunat šum
- ...

Razne metode lokalizacije već unutar svog tijeka izvođenja imaju metode koje prate veličinu relativne pogreške te ju pokušaju minimizirati nakon svake iteracije ali ta pogreška i dalje postoji te će uvijek i postojati. Te pogreške se robota koji rade u skladištima ne moraju uzeti previše ozbiljno, dok se kod autonomnih vozila u svakodnevnome cestovnom prometu ili industrijskih robota te pogreške moraju uvijek uzeti u obzir.

3. Priprema podataka

3.1. Simulator

Za točne referentne podatke potrebno je imati simulirano okruženje. Takvo simulirano okruženje se zove simulator. Potreban je simulator koji već ima integrirane razne mape, razne senzore, vozila te način komunikacije s tim vozilima iz vanjskih skripti. Neki od simulatora su opisani u sljedećem tekstu.

Carla



Slika 3.1: Carla logo[4]

Carla[5] je simulacijsko okruženje koje služi za testiranje metoda i algoritama prilikom razvoja autonomnih vozila. U pozadini koristi Unreal Engine za izvršavanje simulacije. Simulator se ponaša kao poslužitelj koji prima naredbe iz vanjskih klijentskih programa. Ti klijentski programi su pisani u programskom jeziku python. Carla ima integrirane razne senzore te su neki od njih RGB kamera, Lidar senzor, senzor dubine, GNSS, ... Sponzori projekta su Intel, Toyota, GM i Computer vision Center. Više o ovome simulatoru će biti u sljedećem poglavlju.

Apollo



Slika 3.2: Apollo logo[10]

Apollo je također rješenje za testiranje autonomnih vozila. Sadrži simulator ali također je i potpuno komercijalno rješenje. Podržava razne scenarije, ima sustav ocjenjivanja koji daje ocjenu na temelju desetak metrika. Simulacije zapravo provodi u oblaku tj. koristi Microsoft Azure. Sponzori projekta su mnoge azijske tvrtke kao i Ford, Microsoft, Daimler, Honda, Intel i ostali.

rFpro



Slika 3.3: rFpro logo[13]

rFpro je kompletno rješenje za testiranje autonomnih vozila. U potpunosti je komercijalno rješenje ali je zato jedno od najboljih u svijetu. Uglavnom je usredotočeno na primjenu strojnog učenja u autonomnim vozilima. Ima jednu od najvećih baza digitaliziranih stvarnih likacija diljem svijeta. Dinamički sustav vremena omogućuje testiranje ponašanja vozila u raznim vremenskim uvjetima. Sponzori projekta su BMW, Shell, GM, Renault i ostali.

AVSimulation




Slika 3.4: AVSimulation logo[11]

AVSimulation se zapravo sastoji od simulatora vožnje i samog simulatora SCANeR. SCANeR je skup aplikacija koji pružaju rute, senzore, vozila, dinamičko vrijeme, pisanje skripti. Vrlo je modularan. Simulator vožnje je zapravo kupola koja se sastoji od cijelog vozila te se zapravo kretanje tog vozila simulira unutar te kupole. Sponzori su Renault, PSA, Volvo, Microsoft, Mazda i ostali.

3.2. Opis okruženja

Za okruženje se koristi Carla simulator zbog širokog programskog sučelja i otvorenosti koda, tekođer je besplatno za korištenje u sve svrhe. Simulator se pokreće kao poslužitelj te se vozila dodaju pomoću skripte koja je napisana u programskom jeziku python.



Slika 3.5: Primjer karte pod nazivom Town03

Na slici 3.5 se vidi izgled karte simuliranoga prostora. Korištene mape su definirane OpenDrive standardom. Simulator podržava raznolike senzore. Svi ti senzori se mogu postaviti samostalno na mapu, ali su najkorisniji kada se postave na drugo vozilo.


RGB senzor



Slika 3.6: Primjer regularne kamere[12]

RGB senzor simulira kameru koja može snimati sliku koristeću crvenu, zelenu i plavu boju, tj. regularnu kameru. Ovaj senzor može prikupljati podatke iz simulatora u video obliku ili kao niz slika. Ovaj senzor se može koristiti u metodama lokalizacije koje kao temeljni algoritam koriste prepoznavanje ostalih sudionika u prometu prema obliku tj algoritmi prepoznavaju kontekst slike.


Senzor dubine



Slika 3.7: Primjer rezultata senzora dubine[12]

Ovaj senzor koristi nizove projicirajućih točaka da bi ilustrirao udaljenosti objekata, original na slici 3.7. Tada se ti podaci pretvaraju u crno bijelu sliku gdje je svaki pixel u nijansama sive boje tj. ovisno koliko je objekt na određenome pixelu odaljen od kamere imati će svijetliju nijansu, konvertirano na slici 3.7.


Semantičke segmentacije



Slika 3.8: Primjer semantičke segmentacija[12]

Ovaj senzor zapravo nije senzor ali je grupiran u klasu senzora zato što radi na vrlo sličan način kao i ostali senzori u simulatoru. Ovaj senzor dijeli sliku kamere na semantičke dijelove tj. objekte različitog tipa predstavlja drugim bojama. Na slici 3.8 se vidi da je nebo crne boje, auti su plave boje, drveće je zeleno itd. Ovaj način raspoznavanja objekata je moguć samo u simulator zato što nije potrebno razpoznavati objekte na slici već su oni definirani u simuliranoj okolini.

LIDAR senzor



Slika 3.9: LIDAR podaci[12]

LIDAR (eng. light detecting and ranging) senzor je zapravo vertikalni skup lasera koji simuliraju skeniranje od 360 stupnjeva tako da se rotiraju određeni broj puta u sekundi. Povratni podaci senzora su zapravo točke tj. koordinate relativne naspram samoga senzora do kojih su laseri uspjeli doći. Na slici 3.9 se mogu vidjeti takvi podaci vizualizirani u programu MeshLab. Više o ulaznim parametrima senzora kasnije u radu.

Senzor sudara

Ovaj senzor dojavljuje klijentskome programu ako se vozila sudarilo s drugim objektom u simulaciji.

Senzor prijelaza trake

Ovaj senzor dojavljuje klijentskome programu ako vozilo prođe preko trake na cesti.

GNSS senzor

Senzor koji dojavljuje klijentskome programu trenutnu GNSS lokaciju vozila. Ta lokacija se interno računa tako da se lokacija vozila dodaje na geografsku referentnu lokaciju definiranu za cijelu mapu.

Senzor prepreke


Ovaj senzor javlja klijentskome programu ako se ispred vozila nalazi prepreka.

Promet


Postoji povećani broj već unaprijed definiranih vozila koja se mogu koristiti. Mogu se koristiti kao nositelji senzora ili kao ostali sudionici u prometu. Carla ima dobro definirana prometna pravila te semafore da bi simulacija izgledala što vjernije.

3.3. Oblak točaka

Oblak točaka je skupina podataka koji definiraju neki objekt u prostoru. Oblak točaka se obično generira pomoću trodimenzionalnog skenera. Oblaci točaka imaju veliku primjenu u rekonstrukcijama predmeta, vizualizaciji, animaciji, virtualnoj i proširenoj stvarnosti te industrijskoj proizvodnji i kontroli kvalitete. U trodimenzionalnome kartezijevom sustavu svaka točka je definirana s tri atributa, a to su njene x, y i z koordinate. Uz te osnovne podatke svaka točka također može sadržavati i podatke o njenoj boji.



Slika 3.10: Ilustracija točke u kartezijevom koordinatnome prostoru



Slika 3.11: Oblak točaka katedrale u Zagrebu[3]

Na slici 3.11 se vidi skup točaka koji opisuje katedralu u Zagrebu te okolne objekte. Skup se sastoji od oko 22 milijuna točaka. Skup točaka je mnogo jednostavnije koristiti za mapiranje objekata od slika zato što se lakše može obraditi na računalu. Ti podaci su zapravo spremljeni u tekstualne datoteke pa su lako prenosivi i čitljivi. Konkretno metode u ovome radu koriste oblak točaka prikupljen s rotirajućim laserima na vozilu. Jedan taj skup točaka predstavlja stanje okoline vozila u jednome vremenskom trenutku.

3.4. Referentni podaci


Referentni podaci su oni podaci s kojima se uspoređuju rezultati metoda. Ti podaci su generirani u simulatoru te stanje vozila u jednome trenutku u vremenu. Referentni podaci se zapravo sastoje od lokacije i rotacije vozila.

Lokacija

Lokacija vozila je također definirana kao točka u kartezijevom koordinatnome prostoru. Sastoji se od x, y i z koordinata. Slično kao prikazano na slici 3.10.

Rotacija

U trodimenzionalnome prostoru objekt se zapravo može rotirati oko beskonačnoga broja osi ali se u pravilu uzimaju 3 statičke osi. Te osi se nazivaju os skretanja (eng. yaw), os poniranja (eng. pitch) i os valjanja (eng. roll).



Slika 3.12: Ilustracija osi rotiranja [1]

Os rotacije je os koja prolazi u smjeru kretanja vozila (x os), os poniranja je zapravo os okomita s os rotacija (z os), dok je os skretanja okomita na obje prethodne osi (y os). Te osi su ilustrirane na slici 3.12. Rotacija između dva sustava može biti reprezentirana pomoću rotacijskih matrica[18]. Te matrice su veličine 3x3 te predstavljaju rotaciju oko određene osi.

$$R_x(\alpha) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos(\alpha) & -\sin(\alpha) \\ 0 & \sin(\alpha) & \cos(\alpha) \end{pmatrix} \quad (3.1)$$

$$R_y(\beta) = \begin{pmatrix} \cos(\beta) & 0 & \sin(\beta) \\ 0 & 1 & 0 \\ -\sin(\beta) & 0 & \cos(\beta) \end{pmatrix} \quad (3.2)$$

$$R_z(\gamma) = \begin{pmatrix} \cos(\gamma) & -\sin(\gamma) & 0 \\ \sin(\gamma) & \cos(\gamma) & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad (3.3)$$

Za razliku od rotacijskih matrica Eulerova reprezentacija rotacije se sastoji od samo 3 broja. Ta tri broja opisuju sekvencu kojom je objekt rotiran. Rotacija se može opisati na 12 načina zato što se prikazuje dinamička rotacija. Primjeri su XYX , ZZX , YZZ , itd. Objekt u trodimenzionalnome prostoru možemo rotirati pomoću matrica 3.1, 3.2 i 3.3 u prethodni dogovor da se prvo rotira oko x osi, tada oko y osi i naposljetku oko z osi pomoću formule 3.4 gdje su α , β i γ kutevi rotacije oko x, y i z osi.

$$\begin{bmatrix} X_t \\ Y_t \\ Z_t \end{bmatrix} = R(\gamma)R(\beta)R(\alpha) \begin{bmatrix} X_o \\ Y_o \\ Z_o \end{bmatrix} \quad (3.4)$$

Kao kompromis između prednosti i nedostataka prethodnih reprezentacija rotacije objekata koristi se sustav kvaterniona[17] (eng. Quaternion). U matematici kvaterniona su skup brojeva koji proširuju kompleksne brojeve. Rotacija je prikazana kao vektor od 4 komponente. Formula 3.5 prikazuje kako se množe kvaternioni.

$$i^2 = j^2 = k^2 = ijk = -1 \quad (3.5)$$

Jedan kvaternion (jedinični) je definiran kao zbroj skalara a i vektora $[abc]$ te iznosi:

$$q = a + b\hat{i} + c\hat{j} + d\hat{k} \quad (3.6)$$

Ako os rotacije napišemo u obliku $u = u_x\hat{i} + u_y\hat{j} + u_z\hat{k}$ gdje su u_x , u_y i u_z kalarne veličine te je θ kut zakreta te iste osi tada se rotacija može zapisati kao:

$$q = \cos\left(\frac{\theta}{2}\right) - (u_x\hat{i} + u_y\hat{j} + u_z\hat{k}) \sin\left(\frac{\theta}{2}\right) \quad (3.7)$$

Pretvorba kvaterniona u generalnu rotacijsku matricu se provodu na sljedeći način:

$$R = \begin{pmatrix} a^2 + b^2 - c^2 - d^2 & 2bc - 2ad & 2bd + 2ac \\ 2bc + 2ad & a^2 - b^2 + c^2 - d^2 & 2cd - 2ab \\ 2bd - 2ac & 2cd + 2ab & a^2 + b^2 - c^2 + d^2 \end{pmatrix} \quad (3.8)$$


3.5. Izvor podataka

Kao izvor podataka za algoritme se koristi LIDAR senzor. Podaci koje nam vrati senzor su u obliku skupa točaka (eng. point cloud). Lidar senzor je zapravo vertikalan skup lasera.

Građa lidara

Lidar se sastoji od sljedećih glavnih dijelova:

1. Nakošeno zrcalo
2. Servo motor
3. Izvor laserske zrake
4. Detektor laserske zrake
5. Optički rotirajući enkoder



Slika 3.13: Ilustracija građe lidara[14]

Izgled je ilustriran na slici 3.13. Ovaj primjer ima samo jedan laser. Servo motor rotira kućište gdje se nalazi laser te tako omogućuje očitavanje u svih 360 stupnjeva. Danas se zahtjeva da brzine rotacije budu veće od 1000 okretaja u minuti. Nakošeno zrcalo služi za usmjeravanje zrake. Izvor laserske zrake proizvodi lasere u pulsevima. Te zrake se nalaze u infracrvenome valnome području te su sigurne za vid i male energije. Laserski detektor detektira laserske pulseve te dekodira podatke.

Rad lidara

Lidar može sadržavati razne sustave za lokalizaciju i orijentaciju poput GPS-a, inercijskih sustava (IMU) i ostalih. Koristi dvodimenzionalno očitavanje u horizontalnom smjeru i vertikalno polje vida za kreiranje panorame u 360 stupnjeva. Za dekodiranje podataka se koristi vrijeme povratka laserske zrake i valna duljina ako podržava detekciju boje. Postoji mogućnost nepotpunih očitavanja zbog razlike između frekvencije rotacije i frekvencije očitavanja senzora. Općenito se udaljenost predmeta s laserom može izračunati formulom 3.9 gdje je c brzina svjetlosti, a t vrijeme povratka pulsa zrake.

$$D = \frac{ct}{2} \quad (3.9)$$

Ovakav način je pogodan za srednje do velike udaljenosti, dok za vrlo male udaljenosti se koriste druge metode zato što se teško računaju vremena povratka zrake.

Tipovi lidara

Jedna od podjela lidara je po tome gdje se koristi. Tako imamo zračne i zemaljske lidare. Zračni lidari se koriste za mapiranje topologije prostora. Zasada je to najbolji način za mapiranje površina zato što omogućuje filtriranje vegetacije te sa tako lako mogu dobiti topološki podaci. Takvi lidari su pričvršćeni za avion, dron ili helikopter. Zemaljski lidari su postavljeni statički na zemlji. Koriste se u forenzici i rekonstrukciji objekata.

Primjena

Lidar se koristi u geodeziji, geografiji, geologiji, seizmologiji, fizici a u zadnje vrijeme prilikom lokalizacije autonomnih vozila. Također se koriste u agrokulturi prilikom navodnjavanja ili sadnje. Koristi se prilikom klasifikacije biljaka uz pomoć strojnog učenja. U arheologiji se primjenjuje od mapiranja arheoloških nalazišta koja su fizički nedostupna pa do mapiranja oštećenih predmeta.

Prednosti i nedostaci

Prednosti su što se može iskoristiti u mnoge svrhe i možemo dobiti razne informacije o okolini. Također su podaci koji se dobiju vrlo lako obradivi i čitljivi. Jedini nedostatak je brzina obrade tih podataka. Za velike skupove točaka se rijetko koristi obrada u stvarnome vremenu zato što je potrebna velika računalna snaga.

Parametri simuliranoga lidara

S obzirom da je lidar simuliran njegovi parametri nisu vezani uz njegovu izvedbu nego se mogu postaviti po želji. Jedina razlika je što simulirani lidar nema kašnjenje tj. njegova očitavanja su gotovo trenutna što u stvarnome svijetu nikako ne može biti. Možemo mu postaviti sljedeće parametre:

- broj kanala - broj vertikalnih laserskih zraka
- donja granica polja vida - koliko nisko su orijentirani laseri
- gornja granica polja vida - koliko visoko su orijentirani laseri
- ukupan broj točaka - ukupan broj točaka po laseru u pojedinom očitavanju
- frekvencija rotacije - koliko puta se laseri rotiraju u sekundi
- vremenski korak - koliko često se podaci prikupljaju

3.6. Prikupljanje podataka

Podaci su prikupljeni tako da se simulator pokrene u poslužiteljskom načinu rada te se tada pokreće klijentska skripta napisana u python jeziku. Ta skripta uspostavi kontakt s poslužiteljem te se tako šalju naredbe. Te naredbe će zapravo stvoriti naše vozilo, ostale sudionike i senzor. Nakon što smo prikupili dovoljno podataka skripta će obrisati stvorene objekte i spremiti podatke u datoteke. Tada simulator može prekinuti s radom te se ti podaci mogu obrađivati na bilo koji način.

Pokretanje simulatora

```
CarlaUE4.exe \  
  /Game/Carla/Maps/Town01 \  
  -quality-level=Low \  
  -benchmark -fps=15 \  
  -windowed -ResX=800 -ResY=600 \  
  -carla-port=2000 \  

```

Izvorni kod 1: Carla naredba

Simulator Carla se pokreće pomoću python skripte zbog boljeg upravljanja parametrima ali se zapravo sastoji od naredbe pokazane u primjeru 1. Simulacija se pokreće u mapi pod nazivom Town01. Kvaliteta je postavljena na najnižu vrijednost kao i broj slika u sekundi zbog boljih performansi izvođenja. Prozor smo postavili na vrlo malu rezoluciju od 800 pixela širine i 600 pixela visine također zbog boljih performansi. Vrlo važan parametar je sučelje preko kojega klijentski program komunicira s poslužiteljem. Ovdje je definiran kao 2000.

Klijentska kript

Referentni i testni podaci su prikupljeni iz simualtora ali iz različitih izvora. Referentni podaci su prikupljeni iz samoga simulatora dok su testni podaci prikupljeni pomoću senzora.

U primjeru izvornoga koda 3 klijent se spaja na Carla poslužitelj čiju smo lokaciju (IP adresu i sučelje) definirali u klasi `CarlaProp`. Također postavljamo sinkroni način rada simulatora, a razlog je taj što želimo upravljati frekvencijom slanja podataka iz poslužitelja prema klijentima. Varijabla `self.world` služi za izvođenje svih operacija koje su vezane uz svijet.

```
1 class CarlaProp:
2     spawn_delay = 1.0
3     host = "localhost"
4     port = 2000
```

Izvorni kod 2: Carla postavke

```
1 def connect_to_carla(self):
2     self.client = carla.Client(
3         CarlaProp.host,
4         CarlaProp.port
5     )
6     self.client.set_timeout(2.0)
7     self.world = self.client.get_world()
8     settings = self.world.get_settings()
9     settings.synchronous_mode = True
10    self.world.apply_settings(settings)
```

Izvorni kod 3: Uspostava konekcije s poslužiteljem

Svaka karta ima već unaprijed definirane točke stvaranja tj. koordinate u svijetu na kojima možemo stvoriti objekte. Te koordinate se nalaze na cestama. Njih možemo dobiti naredbom prikazanom na primjeru izvornoga koda 4.

```
1 def get_spawn_points(world):
2     return list(world.get_map().get_spawn_points())
```

Izvorni kod 4: Dohvaćanje liste koordinata stvaranja

Sljedeće što slijedi je stvaranje ostalih sudionika prometa tj. ostalih vozila. Carla ima već unaprijed definirane nacрте raznih objekata.

```

1 def get_vehicle_blueprints(world):
2     blueprints = world.get_blueprint_library()
3         .filter('vehicle.*')
4     blueprints = [
5         x for x in blueprints
6         if int(x.get_attribute('number_of_wheels')) == 4
7     ]
8     return [
9         x for x in blueprints
10        if not x.id.endswith('isetta')
11    ]

```

Izvorni kod 5: Dohvaćanje nacrtu vozila

U izvornome kodu 5 se vidi kako se koristi knjižnica nacrtu da bi filtrirali potrebni nacrti. Koriste se samo vozila koja imaju 4 kotača.

```

1 def spawn_npcs(self):
2     blueprints = utils.get_vehicle_blueprints(self.world)
3     points = self.spawn_points[1:self.npc_number+1]
4     for i in range(self.npc_number):
5         actor_blueprint = random.choice(blueprints)
6         actor_spawn_point = points[i]
7         spawned_actor = self.world.try_spawn_actor(
8             actor_blueprint,
9             actor_spawn_point
10        )
11        spawned_actor.set_autopilot()
12        self.npcs.append(spawned_actor)
13    self.tick()

```

Izvorni kod 6: Stvaranje ostalih vozila

Koristeći točke stvaranja i nacrtu vozila sada se mogu ta vozila stvoriti u svijetu. Na 6 se koristeći petljom stvara unaprijed zadan broj ostalih sudionika definiranih u varijabli klase `self.npc_number`. Njihove reference se tada spremaju u listu zato

što se na kraju izvođenja moraju uništiti. Stvaranje instance nacрта se izvodi naredbom na liniji 7. Također se svakoj instanci definira autonomni način rada na liniji 11.

Sada se definira vozilo koje zapravo promatramo tj. koje ima na sebi lidar senzor. To se radi na približno jednak način kao u primjeru 6. Izvorni kod je prikazan na primjeru 7.

```
1 def spawn_actor(self):
2     lib = self.world.get_blueprint_library()
3     spawn_point = self.spawn_points[0]
4     actor_blueprint = utils.get_vehicle_blueprint(lib)
5     self.actor = self.world.spawn_actor(
6         actor_blueprint, spawn_point
7     )
8     self.actor.set_autopilot()
9     self.tick()
```

Izvorni kod 7: Stvaranje promatranoga vozila

Sada slijedi pronalazak nacрта za lidar senzor, postavljanje njegovih atributa, njegovo instanciranje i postavljanje na promatrano vozilo. Izvorni kod je prikazan na 9. Postavke LIDAR senzora se nalaze u klasi LIDARProp.

```
1 class LIDARProp:
2     sensor_tick = str(0.0)
3     channels = str(180)
4     laser_range = str(1500.0)
5     rotation_frequency = str(120.0)
6     points_per_second = str(600_000)
7     upper_fov = str(45.0)
8     lower_fov = str(-80.0)
9     location = carla.Transform(
10         carla.Location(x=0, y=0, z=4)
11     )
```

Izvorni kod 8: LIDAR atributi

Pomoću `sensor_tick` parametra se definira da simulator treba prikupljati podatke najbrže što može. Varijabla `laser_range` definira koliko daleko laser može doprijeti, ovdje je definirano na 1500 centimetara ili 15 metara. Frekvencija rotacije lidara je definirana varijablom `rotation_frequency` i iznosi 120 rotacija u minuti. Gornja granica mjerenja lasera je 45° , a donja je -80° . parametar `location` definira lokaciju lasera tj. bit će u središtu koordinatnog sustava ali na visini od 4 metra. Sredina tog koordinatnog sustava je zapravo sredina unutarnjeg sustava vozila na kojemu će taj senzor biti pričvršćen.

Na liniji 3 primjera 9 se dohvaća nacrt lidar senzora. Tada od linije 4 do 24 se postavljaju zadane postavke nad nacrtom. Konačno na liniji 26 se stvara instanca senzora ali se metodi predaje dodatan parametar `attach_to` koji je jednak referenci na naše vozilo. Također umjesto stvarnih koordinata, za lokaciju senzora se postavlja lokaciju relativnu naspram lokacije vozila. Na liniji 30 se postavlja metoda `lidar_callback()` kao metodu koju će simulator pozvati svaki puta kada senzor očita okolinu i pošalje podatke. Spremanje podataka se izvršava tek nakon što smo sakupili konačan broj očitavanja. Za spremanje podataka u datoteke se koristi posebna klasa `DataSaver` pokazana na primjeru 10.

Primjeri 10 i 11 prikazuju klasu `DataSaver` koja služi za spremanje podataka u datoteke. Datoteke s podacima iz senzora se nalaze u direktoriju s nazivom `poinclouds`, dok se datoteke s podacima o lokaciji vozila nalaze u direktoriju s nazivom `actortransforms`. Oba ta direktorija se nalaze u direktoriju s nazivom *output*. Datoteke s informacijama o lokaciji vozila se sastoje od 2 reda. Prvi red sadrži vremensku oznaku, a drugi sadrži lokaciju i transformaciju koji su opisani u prijašnjem poglavlju. Datoteke koje sadrže podatke o jednome očitavanju se nalaze u tekstualnim datotekama s ekstenzijom `.ply` te se sastoji od zaglavlja i po jedan redak za svaku točku u očitavanju. Također postoji još jedna datoteka koja samo sadrži relativnu transformaciju između senzora i vozila. Ona se nalazi u direktoriju *output*.

Zaglavlje `.ply` datoteke u primjeru 12 ima definiran ukupan broj točaka kao 17252, tipove svake koordinate kao 32 bitni broj s pomičnim zarezmom, te poredak koordinate u svakoj liniji, a to je prvo x, y pa zatim z.

```

1     def connect_LIDAR(self):
2         lib = self.world.get_blueprint_library()
3         blueprint = utils.get_lidar_sensor_blueprint(lib)
4         blueprint.set_attribute(
5             'sensor_tick', LIDARProp.sensor_tick
6         )
7         blueprint.set_attribute(
8             'channels', LIDARProp.channels
9         )
10        blueprint.set_attribute(
11            'range', LIDARProp.laser_range
12        )
13        blueprint.set_attribute(
14            'rotation_frequency', LIDARProp.rotation_frequency
15        )
16        blueprint.set_attribute(
17            'points_per_second', LIDARProp.points_per_second
18        )
19        blueprint.set_attribute(
20            'upper_fov', LIDARProp.upper_fov
21        )
22        blueprint.set_attribute(
23            'lower_fov', LIDARProp.lower_fov
24        )
25        utils.print_sensor_blueprint_data(blueprint)
26        self.lidar = self.world.try_spawn_actor(
27            blueprint, LIDARProp.lidar_relative_postion,
28            attach_to=self.actor
29        )
30        self.lidar.listen(
31            lambda data: self.lidar_callback(data)
32        )
33        self.tick()

```

Izvorni kod 9: Stvaranje LIDAR senzora

```

1 import utils as utils
2 import time
3 import threading
4 from concurrent.futures import
5     ThreadPoolExecutor, as_completed
6 from lidar_properties import LIDARProperties
7
8 class DataSaver:
9     def __init__(self):
10         self.pc_path = 'output/pointclouds'
11         self.trans_path = 'output/actortransforms'
12         self.rel_path = 'output/relative_transform.txt'
13     def initialize_folders(self):
14         utils.create_directory(self.trans_path)
15         utils.create_directory(self.pc_path)
16     def save(self, scans):
17         self.initialize_folders()
18         self.save_rel_trans()
19         start_time = time.time()
20         with ThreadPoolExecutor(max_workers=10) as executor:
21             jobs = list()
22             for i, (scan, transform) in enumerate(scans[1:]):
23                 job = executor.submit(
24                     self.process_pair, scan, transform, i
25                 )
26                 jobs.append(job)
27             for future in as_completed(jobs):
28                 future.result()

```

Izvorni kod 10: Klasa za spremanje podataka

```

1  def process_pair(self, scan, trans, i):
2      frame_number = scan.frame_number
3      s_path = f'{self.pc_path}/{frame_number:06d}.ply'
4      self.save_scan(scan, s_path, i + 1)
5      tpath = f'{self.trans_path}/{frame_number:06d}.txt'
6      self.save_transform(
7          trans, scan.timestamp, tpath, i + 1
8      )
9  def save_rel_trans(self):
10     with open(self.rel_path, 'w+') as file:
11         file.write(
12             utils.transform_to_string(LIDARProp.location)
13         )
14  def save_scan(self, scan, path, i = 0):
15     scan.save_to_disk(path)
16  def save_transform(self, trans, timestamp, path, i = 0):
17     with open(path, 'w+') as file:
18         file.write(
19             f"{timestamp}\n{utils.transform_to_string(trans)}"
20         )

```

Izvorni kod 11: Klasa za spremanje podataka - nastavak

```
ply
format ascii 1.0
element vertex 17252
property float32 x
property float32 y
property float32 z
end_header
-6.6331 4.7159 -3.6613
-7.6668 3.6868 -3.6721
-6.8233 4.8510 -3.6132
-7.2357 4.3627 -3.6467
-7.5643 3.8149 -3.6567
-6.8332 4.8581 -3.5678
-9.3522 -2.1228 -9.5902
-9.4462 -2.5989 -9.7976
-8.9343 -2.8991 -9.3936
-9.0191 -3.3851 -9.6346
-9.0191 -3.8595 -9.8117
-9.0191 -4.3526 -10.0164
-9.0191 -4.8679 -10.2512
.
.
.
```

Izvorni kod 12: Izgled sadržaja .ply datoteke

4. Algoritmi lokalizacije

4.1. Obitelj algoritama

Algoritmi korišteni za obrađivanje senzorskih podataka pripadaju ICP[16] (eng. iterative closest point) obitelji algoritama. Koristi se za minimizaciju razlika dvije skupine točaka. U ovome slučaju se koristi za minimizaciju razlike između dva oblaka točaka prikupljenih pomoću lidar senzora. Ovaj algoritam radi tako da se jedan skup točaka postavi kao referentni dok se drugi skup pokušava transformirati, uz minimiziranje razlike, u referentni skup. Algoritam iterativno poboljšava transformaciju potrebnu za minimiziranje pogreške. Za računanje pogreške se mogu koristiti kvadratična razlika koordinata dviju točaka. ICP algoritam je jedan od najkorištenijih algoritama za rekonstrukcije trodimenzionalnih objekata te su ga prvi puta predstavili Besl i McKay[2].

Ulaz i izlaz algoritma

Ulazi algoritma su referentni i ciljni skupovi točaka, kriterij zaustavljanja iteriranja algoritma te opcionalna inicijalna transformacija tj. translacija i rotacija. Izlaz algoritma je u pravilu matrica koja se sastoji od rotacijskih i translacijskih podataka te karakterističan fitness broj koji prikazuje koliko dobro je poravnanje dvaju skupa točaka zapravo bilo. Izgled izlaza je prikazan na martici 4.1.

$$T = \begin{pmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (4.1)$$

Matrica se zapravo sastoji od rotacijske matrice veličine 3x3 koja se sastoji od elemenata r_{11} do r_{33} , te od translacijske matrice koja se sastoji od elemenata t_x , t_y i t_z .

Pseudokod ICP algoritma

Result: Transformacijska matrica

priprema skupa točaka P i Q;

while *uvjet zaustavljanja nije zadovoljen* **do**

 pronađi najbliže točke iz skupova (p_i i q_i);

 estimiraj transformacijsku matricu R minimizirajući

$$\min_{R,t} \sum_i ||p_i - Rq_i - t||^2;$$

end

Ukratko ovaj algoritam prolazi kroz svaku točku ciljnoga skupa ili podskupa točaka te traži najbližu točku u referentnome skupu. Tada estimira kombinaciju rotacije i translacije ta bi poravnao te dvije točke tako što računa srednju vrijednost kvadrata razlike koordinata točaka. Algoritam tada to izvodi za ostale točke te se zaustavlja kada dosegne uvjet zaustavljanja. Taj uvjet može biti postavljen kao broj iteracija ili kao minimalna dopuštena vrijednost pogreške. Ovaj algoritam se može optimizirati na razne načine. Moguće je prvo detektirati posebne podskupove točaka unutar oblaka te eliminirati ostale točke. Također se mogu filtrirati točke koje nisu od interesa. Tako se smanjuje količina točaka koje treba usporediti.

Neke od tih metoda filtriranja su:

1. Grupiranje točaka gdje se cjeli skup točaka dijeli na više područja oblika kocke te se unutar njih filtriraju sve točke osim jedne koja će predstavljati taj skup.
2. Statističko filtriranje radi tako da izračuna srednju udaljenost do k najbližih točaka te filtrira samo točke unutar te udaljenosti. Temelji se na Gausovoj raspodjeli.
3. Filtracija temeljena na promjeru samo filtrira točke koje su unutar promjera d oko točke.
4. Uvjetno filtriranje koristi uvjete za filtraciju točke. Uvjet može biti da se točka samo uzima u obzir ako joj je koordinata z manja od 15.

PCL biblioteka



Slika 4.1: PCL logo[7]

Za izvođenje ICP algoritma se koristi već gotova implementacija algoritma koja je dio biblioteke PCL[6] (eng. Point Cloud Library). Zbog širokog broja algoritama i alata se smatra standardnom bibliotekom za obradu oblaka točaka te lokalizaciju. To je biblioteka otvorenoga koda koja se sastoji od implementacija raznih algoritama za obradu dvodimenzionalnih i trodimenzionalnih podataka. Sastoji se od algoritama za detekciju oblika, rekonstrukciju površina, obradu oblaka točaka. Sama biblioteka je napisana u jeziku C++ te ima vrlo visoke performanse i mogućnost izvođenja na raznim platformama od autonomnih automobila do ugrađenih računalnih rješenja u prijenosnim uređajima poput mobilnih uređaja. Kombinacijom PCL biblioteke i senzora mobilnih uređaja može se koristiti za proširenu ili virtualnu stvarnost.

4.2. Dijeljeni kod i ulazni podaci

Kod u nastavku je zajednički za oba algoritma tj. nema veze s samim algoritmom već služi za dohvat podataka i spremanje rezultata algoritma. Sastoji se od metoda za čitanje datoteka s informacijama o oblacima točaka i metoda za spremanje transformacijskih matrica u datoteke.

```
1 typedef PointXYZ PT;
2 typedef PointCloud<PT> PointCloudType;
3 typedef IterativeClosestPoint<PT, PT, double> ICP;
4
5 PointCloudType::Ptr cloud_ref(new PointCloudType());
6 PointCloudType::Ptr cloud_target(new PointCloudType());
7 PointCloudType::Ptr cloud_reg(new PointCloudType());
8
9 PointCloudType::Ptr cloud_ref_f(new PointCloudType());
10 PointCloudType::Ptr cloud_target_f(new PointCloudType());
11
12 string root_point_clouds = "\\point_clouds\\";
13 string root_results = "\\icp_results\\";
```

Izvorni kod 13: Generalizirani ICP - konstante

U primjeru izvornoga koda 13 su definirane konstante poput putanje za spremanje rezultata i putanje s ulaznim datotekama. Također su definirani tipovi točaka `PT` kao `PointXYZ` koje će algoritam koristiti te sadrže samo `x`, `y` i `z` koordinate. Mogu se koristiti i drugi oblici točaka. Oblak točaka `PointCloudType` je definiran kao kolekcija prethodno definiranih točaka. Naposljetku se definira tip `ICP` algoritma tj. s kojim tipovima podataka radi. Definiran je pomoću uređene trojke `<PT, PT, double>` što znači da uspoređuje točke tipa `PT`, a rezultate u transformacijsku matricu zapisuje kao `double` vrijednosti tj. kao brojeve s pomičnim zarezom dvostruke preciznosti.

Definirane su i varijable `cloud_ref` koja pokazuje na referentni skup točaka, `cloud_target` koja pokazuje na ciljni skup točaka i `cloud_reg` koja pokazuje na aproksimiran skup točaka nakon poravnanja. Za algoritme koji koriste filtrirane oblake točaka koriste se varijable `cloud_ref_f` i `cloud_target_f`. One su tipa `boost::shared_ptr` te se kao takve predaju metodama kao pokazivači.

```

1 ICP setupICP() {
2     ICP icp;
3     icp.setMaxCorrespondenceDistance(0.05);
4     icp.setMaximumIterations(500);
5     icp.setTransformationEpsilon(1e-8);
6     icp.setEuclideanFitnessEpsilon(1);
7     return icp;
8 }

```

Izvorni kod 14: Instance ICP algoritma

U primjeru 14 se definira ICP algoritam tako da mu se predaju uvjeti zaustavljanja te ostali parametri. Trenutno su zadana tri uvjeta zaustavljanja, a oni su:

1. `setMaxCorrespondenceDistance` - uzima u obzir samo točke unutar zadanoga promjera u metrima
2. `setMaximumIterations` - maksimalan broj iteracija prilikom estimacije transformacije za neku točku
3. `setTransformationEpsilon` - maksimalna dozvoljena pogreška

```

1 vector<path> get_files() {
2     vector<path> paths;
3     path p(root_point_clouds);
4     directory_iterator end_itr;
5     for (directory_iterator itr(p); itr != end_itr; ++itr) {
6         if (is_regular_file(itr->path())) {
7             paths.push_back(itr->path());
8         }
9     }
10    return paths;
11 }

```

Izvorni kod 15: Skupljanje ulaznih datoteka

Kod u primjeru 15 koristi metode biblioteke Boost[9] za iteriranje datoteka sa skupovima točaka te vraća vektora s njihovim putanjama. Kod za stvaranje grafova je jednak bez obzira na korišteni algoritam. Grafovi su stvoreni pomoću jezika Kotlin i biblioteke XCharts. Podaci koji vizualiziraju su usporedbe stvarnih podataka tj. referentnih i podataka dobivenih pomoću algoritama. S obzirom da nam algoritmi kao izlaz daju samo transformacijske matrice, potrebno je nekako te matrice prikazati kao koordinate lokacija i kuteve rotacija.

```

1 fun calculatePointsExperimental (
2   icp: List<TransformMatrix>,
3   first: Transform
4 ): List<Array<DoubleArray>> {
5   val transformations = mutableListOf<pointToMat(first)>()
6   val last = transformations.last()
7   icp.forEach { transform ->
8     val result = mult(last, transform.matrix)
9     transformations.add(result)
10  }
11  return transformations
12 }

```

Izvorni kod 16: Generiranje estimiranih transformacijskih matrica

Kod u primjeru 16 se vidi metoda za generiranje estimiranih točaka iz prve referentne točke i transformacijskih matrica. Kao argumente metoda prima listu transformacijskih matrica `icp` te transformaciju prve referentne točke. Algoritam radi tako da prvo izračuna transformacijsku matricu iz prve referentne točke pomoću metode 17. Zapravo se rotacija iz Eulerovog oblika pretvara u zasebne rotacijske matrice te njih pomnoži redosljedom XYZ zbog redosljeda rotacija prilikom ICP estimacije transformacije oblaka točaka. Izgledi pojedinih matrica su prikazani u poglavlju Referentni podaci. Tada se vraća matricu veličine 4x4 koja se sastoji od rotacijske matrice i lokacija. Algoritam koristi prethodno estimiranu transformacijsku matricu te trenutnu estimiranu transformacijsku matricu tako da iz pomnoži pravilima množenja matrica. Tada se dobije nova matrica koja zapravo predstavlja nove koordinate i nove rotacije naspram prethodne. Na liniji 7 primjera 16 se vidi kako se zapravo primjenjuje formula $R = R_z(\gamma)R_y(\beta)R_x(\alpha)$. Taj redosljed množenja matrica rotacija je vrlo bitan.

```

1 fun pointToMat(first: Transform): Array<DoubleArray> {
2     val rot = first.rotation
3     val loc = first.location
4     val rx = rot.toRx()
5     val ry = rot.toRy()
6     val rz = rot.toRz()
7     val res = multi(rz, multi(ry, rx))
8     return arrayOf(
9         arrayOf(res[0][0], res[0][1], res[0][2], loc.x),
10        arrayOf(res[1][0], res[1][1], res[1][2], loc.y),
11        arrayOf(res[2][0], res[2][1], res[2][2], loc.z),
12        arrayOf(0.0, 0.0, 0.0, 1.0)
13    )
14 }

```


Izvorni kod 17: Generiranje estimiranih lokacija

Vizualizacije referentnih podataka za oba primjera kretanja vozila možemo vidjeti na sljedećim grafovima. Na njima svaka točka predstavlja jedno očitavanje. Slika 4.2 prikazuje graf lokacija vozila. Slika 4.3 pokazuje koordinate vozila u vremenu. Možemo vidjeti da se mijenjaju samo x i y koordinate zato što vozilo može samo skretati. Slika 4.4 prikazuje valjanje, poniranje i skretanje oko statičnih osi vozila u vremenu. Također se može uočiti da se samo skretanje mijenja zato što se vozilo ne može valjati niti ponirati. Slika 4.5 također pokazuje rotaciju vozila u vremenu ali predstavljenu u obliku kvaterniona.

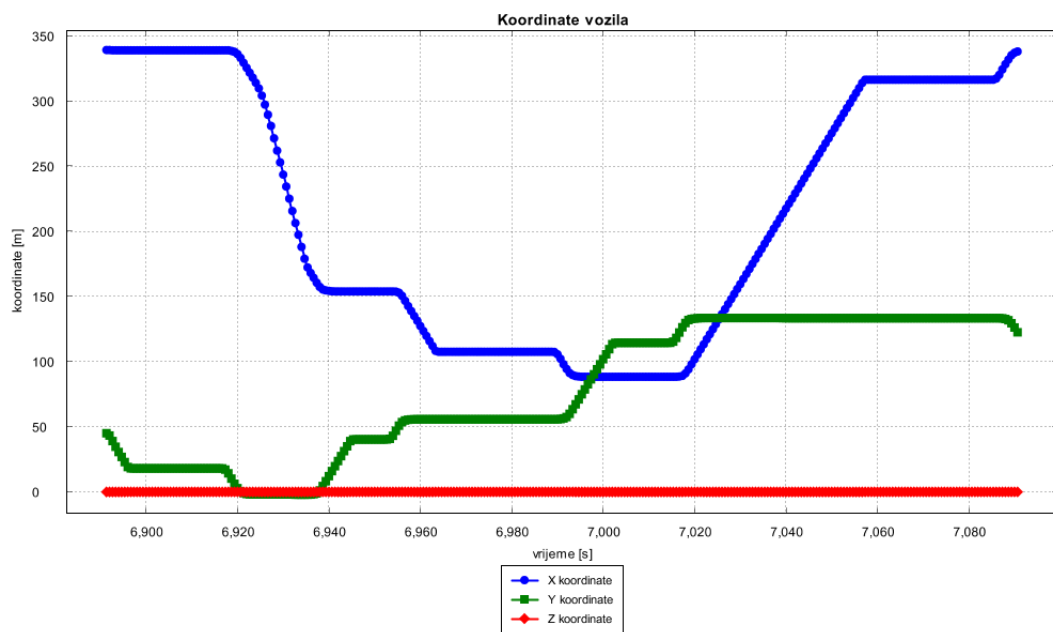
Primjer referentnih podataka A

Prvi skup podataka se sastoji od 300 očitavanja tj. postoji 300 datoteka sa skupovima točaka. Duljina trajanja te simulacije je 200 sekundi. Parametri koji su korišteni u python skripti za postavljanje lidar senzora su sljedeći:


1. Maksimalna udaljenost laserske zrake je postavljena na 1500 cm tj. 15 metara
2. Maksimalan skup točaka u jednome očitavanju je postavljen na 600 000.




Slika 4.2: Graf lokacije vozila



Slika 4.3: Graf x, y i z koordinata vozila u vremenu



Slika 4.4: Valjanje, skretanje i poniranje vozila u vremenu




Slika 4.5: Rotacija vozila u obliku kvaterniona


Primjer referentnih podataka B

Drugi skup podataka se sastoji od 600 očitavanja tj. postoji 600 datoteka sa skupovima točaka. Duljina trajanja te simulacije je 80 sekundi. Parametri koji su korišteni u python skripti za postavljanje lidar senzora su sljedeći:

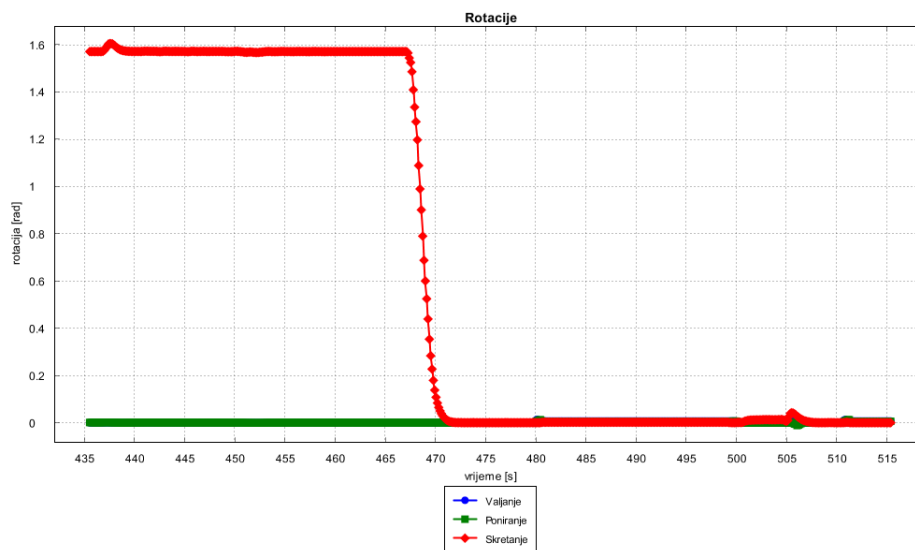
1. Maksimalna udaljenost laserske zrake je postavljena na 2000 cm tj. 20 metara
2. Maksimalan skup točaka u jednome očitavanju je postavljen na 1 000 000.



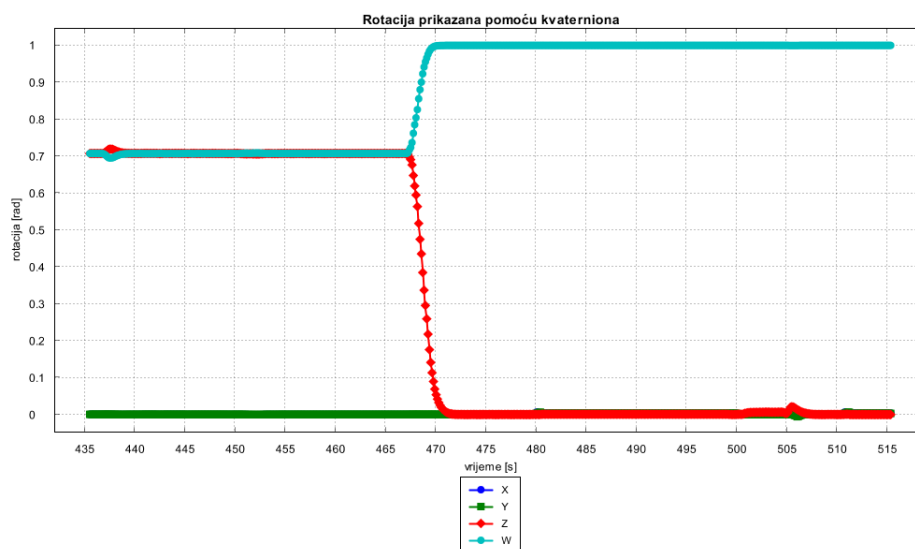
Slika 4.6: Graf lokacije vozila



Slika 4.7: Graf x, y i z koordinata vozila u vremenu



Slika 4.8: Valjanje, skretanje i poniranje vozila u vremenu



Slika 4.9: Rotacija vozila u obliku kvaterniona

Prvi niz skupova točaka se skupljao u dužem periodu ali ima samo 300 skupova zato što se koristi svako 15 očitavanje. Drugi niz skupova točaka ima 600 očitavanja zato što se uzima svako očitavanje. Također je drugi skup detaljniji od prvoga što pridonosi točnosti algoritama. Duljinu puta možemo izračunati tako da pronađemo udaljenosti između dvije sljedne točke te ih zbrojimo. Tako dobivena udaljenost za referentni primjer A iznosi 662.3 metra, a za referentni primjer B iznosi 448.2 metra.

```

1 void save_matrix(ICP icp, string first, string second) {
2     Matrix4d transformation = icp.getFinalTransformation();
3     double fitness = icp.getFitnessScore();
4     string filename = first + "-" + second + ".txt";
5     Matrix3d mat = mat4x4_to_3x3(transformation);
6     Vector3d rpy = mat.eulerAngles(0, 1, 2);
7     save_to_file(
8         filename,
9         mat_to_string(transformation),
10        fitness,
11        rpy
12    );
13 }

```

Izvorni kod 18: Generalizirani ICP - spremanje rezultata

Spremanje rezultata se vrši metodom `save_matrix` u primjeru 18. Matricu transformacije možemo dobiti pozivom `icp.getFinalTransformation()` te je oblika `Matrix4d` tj. ima 4 redaka i 4 stupaca dok su elemnti tipa `double`. Ta matrica se tada transformira u matricu veličine 3x3 tj. izdvaja se rotacijska matrica zato što takav tip matrice ima ugrađenu metodu `eulerAngles()`. Ta metoda kao argumente prima redosljed rotacija objekta tj. redosljed osi rotacija. U ovome slučaju se prvo predaje 0 što znači da se objekt prvo rotirao oko x osi, tada se predaje 1 što znači da se tada rotirao oko y osi i naposljetku se predaje 2 što znači da je zadnja rotacija bila oko z osi. Metoda vraća vektor od tri elementa koji predstavljaju valjanje, poniranje i skretanje. Konačno se sve te informacije spremaju u datoteku s imenom sastavljenim od dva indetifikatora očitavanja tako da se zna koji skupovi točaka su upoređivani. Struktura te datoteke je prikazana na primjeru 19. Prva linija sadrži fitnes vrijednost. Od druge do pete linije se nalazi transformacijska matrica dok se na zadnjoj liniji nalaze Eulerovi kutevi u radijanima.

0.0263544				
0.999735	-0.0230172	-0.00046344	-0.00394583	
0.0230173	0.999735	0.000237121	0.000806379	
0.000457859	-0.000247725	1	0.0091155	
0	0	0	1	
3.14136	-3.14113	-3.11857		

Izvorni kod 19: ICP - datoteka s rezultatom

$$AM_x = \frac{1}{n} \sum_{i=0}^{n-1} |X_i - \hat{X}_i|$$

$$AM_y = \frac{1}{n} \sum_{i=0}^{n-1} |Y_i - \hat{Y}_i| \quad (4.2)$$

$$AM_z = \frac{1}{n} \sum_{i=0}^{n-1} |Z_i - \hat{Z}_i|$$

$$MSE_x = \frac{1}{n} \sum_{i=0}^{n-1} |X_i - \hat{X}_i|^2$$

$$MSE_y = \frac{1}{n} \sum_{i=0}^{n-1} |Y_i - \hat{Y}_i|^2 \quad (4.3)$$

$$MSE_z = \frac{1}{n} \sum_{i=0}^{n-1} |Z_i - \hat{Z}_i|^2$$

$$ROT_r = \frac{1}{n} \sum_{i=0}^{n-1} |R_i - \hat{R}_i|$$

$$ROT_p = \frac{1}{n} \sum_{i=0}^{n-1} |P_i - \hat{P}_i| \quad (4.4)$$

$$ROT_y = \frac{1}{n} \sum_{i=0}^{n-1} |Y_i - \hat{Y}_i|$$

$$ROT_r = \frac{1}{n} \sum_{i=0}^{n-1} |R_i - \hat{R}_i|^2$$

$$ROT_p = \frac{1}{n} \sum_{i=0}^{n-1} |P_i - \hat{P}_i|^2 \quad (4.5)$$

$$ROT_y = \frac{1}{n} \sum_{i=0}^{n-1} |Y_i - \hat{Y}_i|^2$$

Konkretnije numeričke estimacije i pogreške se računaju pomoću sljedećih formula. Sretnja aritmetička vrijednosti razlika koordinata i rotacija se računa s formulama 4.2 i 4.4. Element n je ukupan broj točaka, X_i je stvarna vrijednost koordinate x , dok je \hat{X}_i estimirani iznos x koordinate. Po istome principu vrijedi za x i y koordinate. Element R_i je stvarna vrijednost kuta valjanja, dok je \hat{R} estimirana vrijednost kuta valjanja. Po istome principu vrijedi za skretanje i poniranje. Srednje kvadratične pogreška koordinata i rotacije se računaju s formulama 4.3 i 4.5. AM znači aritmetička sredina razlika, dok MSE znači srednja kvadratična pogreška. Prilikom računanja srednjih pogrešaka kuteva, a tako i razlike kuteva, uzeta je periodičnost kuteva u obzir.

5. Algoritmi

5.1. Generalizirani ICP algoritam

Opis algoritma

Ovaj način uspoređivanja skupova točaka je najjednostavniji. Ne tražimo prepoznatljive oblike niti imamo ikakve posebne optimizacije. Kao ulaz koristimo niz .ply datoteka. Svaka ta datoteka predstavlja jedan skup točaka tj. jedno očitavanje lidar-a. Oblik datoteke je prikazan na slici 12. Program radi tako da otvori dvije datoteke koje predstavljaju dva sljedna očitavanja. Tada njihov sadržaj preda metodi koja vraća transformacijsku matricu i fitnes veličinu. Za rad s datotekama se koristi Boost biblioteka otvorenoga koda.

Izvorni kod algoritma

Metodom `process_files` u primjeru 20 se iterira kroz datoteke te se otvaraju u parovima i njihov sadržaj tj. informacije o oblaku točaka se spremaju u globalne varijable `cloud_ref` i `cloud_target`. Na linijama 11 i 12 se postavljaju dodatni ulazni parametri ICP algoritmu. Konačno se pokreće algoritam te se ispituje ako je došlo do konvergencije. Do konvergencije dolazi ako su dva skupa oblaka slična tj. ako predstavljaju isti objekt ali rotiran i/ili translantiran. Očekuje se da uvijek dođe do konvergencije u ovome primjeru. Ako je došlo do konvergencije, spremamo podatke u datoteku. Naposljetku se iz optimizacijskih razloga vrijednost matrice `cloud_target` sprema kao referentni skup točaka.

```

1 void load_point_cloud(string path, PointCloudType& cloud) {
2     pcl::io::loadPLYFile(path, cloud);
3 }
4
5 void process_files(vector<path> paths, ICP icp) {
6     for (int i = 0; i < paths.size() - 1; i++) {
7         if (i == 0) {
8             load_point_cloud(paths.at(i).string(), *cloud_ref);
9         }
10        load_point_cloud(paths.at(i + 1).string(), *cloud_target);
11
12        string first = paths.at(i).stem().string();
13        string second = paths.at(i + 1).stem().string();
14
15        icp.setInputCloud(cloud_ref);
16        icp.setInputTarget(cloud_target);
17        icp.align(*cloud_ref);
18
19        if (icp.hasConverged()) {
20            save_matrix(icp, first, second);
21        }
22        *cloud_ref = *cloud_target;
23    }
24 }

```

Izvorni kod 20: Generalizirani ICP - obrada datoteka

5.2. ICP algoritam s grupiranjem točaka

Opis algoritma

Koristi se metoda iteracije najbližih točaka s grupiranjem točaka[8]. Radi tako da se cijeli oblak točaka podijeli na kocke zadane veličine te se tada unutar te kocke filtriraju točke na temelju njihove centroide[15]. U jednome od očitavanja iz primjera A se broj točaka s 35222 smanjio na 1548 što značajno ubrzava ICP algoritam. Ovaj algoritam zapravo aproksimira skup točaka samo jednom točkom. U primjeru 22 se vidi da je parametar visine, širine i duljine kocke uvijek jednak i iznosi 1 centimetar što znači da će se oblak točaka podijeliti na kocke veličine 1 centimetar. Performanse toga algoritma kao i točnost reprezentacije originalnog oblaka ovise o tom parametru kao i gustoći točaka.

Izvorni kod algoritma

Kod je vrlo sličan kao i u prethodnome algoritmu samo što sada imamo jedan korak više prije obrade oblaka ICP algoritmom. Doajemo linije 13 i 17 s pozivima metode 21. Unutar nje se inicijalizira objekt tipa `VoxelGrid<PT>`. Kao parametre prima oblak točaka i veličinu područja na koje će podijeliti oblak točaka.

```
1 void downsample_using_voxel_grid(  
2     PointCloudType::Ptr& cloud,  
3     float width, float height, float length,  
4     PointCloudType::Ptr& downsampled  
5 ) {  
6     VoxelGrid<PT> vg;  
7     vg.setInputCloud(cloud);  
8     vg.setLeafSize(width, height, length);  
9     vg.filter(*downsampled);  
10 }
```

Izvorni kod 21: Metoda za grupaciju točaka

```

1 void process_files(vector<path> paths, ICP icp) {
2     for (int i = 0; i < paths.size() - 1; i++) {
3         if (i == 0) {
4             load_point_cloud(paths.at(i).string(), *cloud_ref);
5         }
6         load_point_cloud(paths.at(i + 1).string(), *cloud_target);
7
8         string first = paths.at(i).stem().string();
9         string second = paths.at(i + 1).stem().string();
10
11         if (i == 0) {
12             downsample_using_voxel_grid(
13                 cloud_ref, 1.0f, cloud_ref_filtered
14             );
15         }
16         downsample_using_voxel_grid(
17             cloud_target, 1.0f, cloud_target_filtered
18         );
19
20         icp.setInputCloud(cloud_ref_filtered);
21         icp.setInputTarget(cloud_target_filtered);
22         icp.align(*cloud_ref);
23
24         if (icp.hasConverged()) {
25             save_matrix(icp, first, second);
26         }
27         *cloud_ref = *cloud_target;
28     }
29 }

```

Izvorni kod 22: ICP grupacija točaka - obrada oblaka

6. Eksperimentalni rezultati

6.1. Generalizirani ICP algoritam

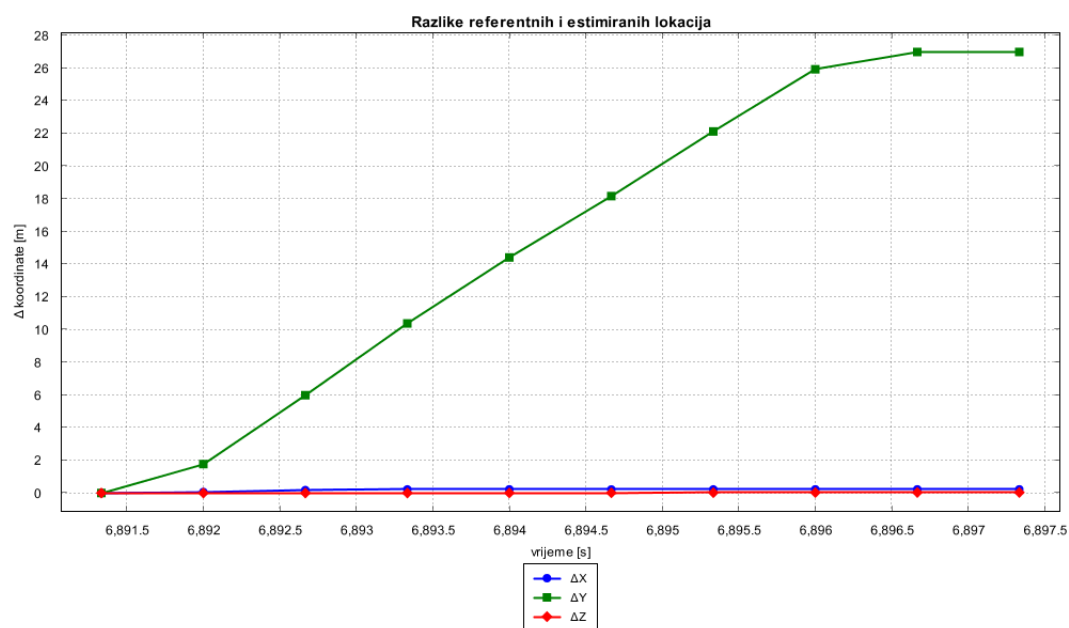
Eksperimentalni rezultati za generalizirajući algoritam iteracije točaka su prikazani u sljedećim tablicama i grafovima. Grafovi i tablice se odnose na podskupove točaka primjera A i B. Zbog fizičke ograničenosti računala ICP algoritam je izvršen na manjem skupu podataka. Može se zaključiti da mnogo faktora utječe na točnost estimacije lokacija i rotacija. Neki od njih su složenost okoline, brzina prikupljanja podataka, ubrzanja vozila, tip algoritma, ...

Tablica eksperimentalnih rezultata

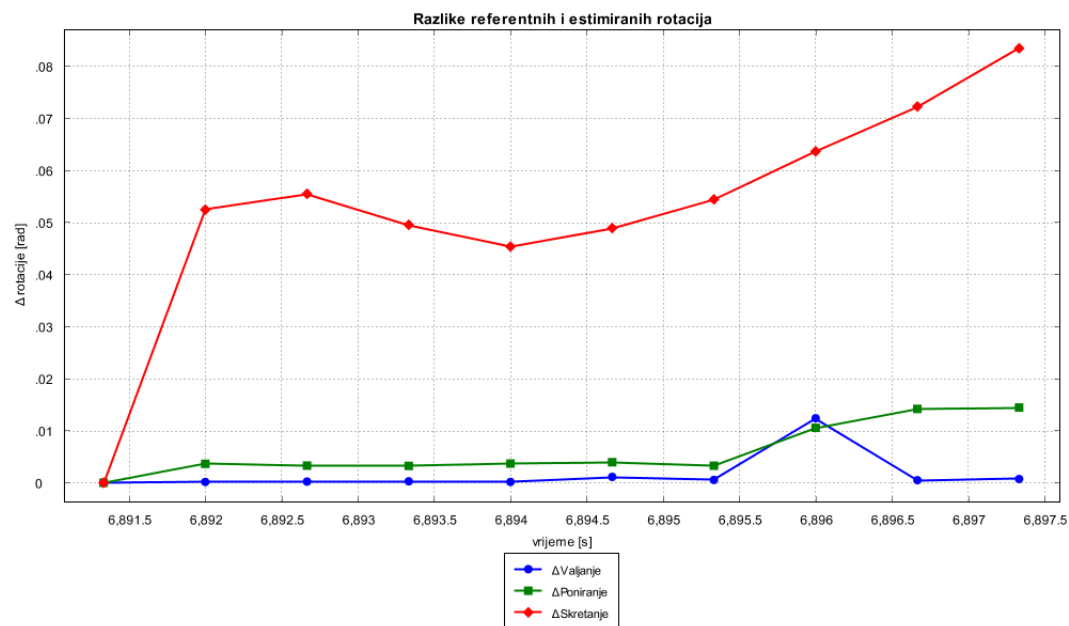
Rezultati	Primjer 1	Primjer 2	Primjer 3	Primjer 4
AMx [m]	0.18427	2.7368E-3	1.41374E-3	3.63932E-2
AMy [m]	16.3356	1.38002E-3	2.8428E-3	1.32941E-2
AMz [m]	0.01657	4.02492E-3	5.811E-4	8.78942E-4
AMr [rad]	1.53082E-3	9.69565E-5	4.95289E-5	1.44264E-4
AMp [rad]	6.81777E-3	8.68708E-5	3.69849E-4	2.43620E-4
AMy [rad]	5.63752E-2	2.7926E-2	1.07866E-2	4.73278E-3
MSEx [m^2]	3.9456E-2	1.11415E-5	3.99733E-6	1.70555E-3
MSEy [m^2]	366.32160	2.47215E-6	1.61632E-5	2.75735E-4
MSEz [m^2]	4.89075E-4	2.15913E-5	6.75381E-7	9.8995E-7
MSEr [rad^2]	1.42492E-5	1.17012E-8	4.90623E-9	5.0858E-8
MSEp [rad^2]	7.38958E-5	1.38325E-8	2.73577E-7	8.0916E-8
MSEy [rad^2]	3.71623E-3	1.05195E-3	2.32704E-4	2.94429E-5

Tablica 6.1: Usporedbe referentnih i estimiranih podataka


Grafovi eksperimentalnih rezultata



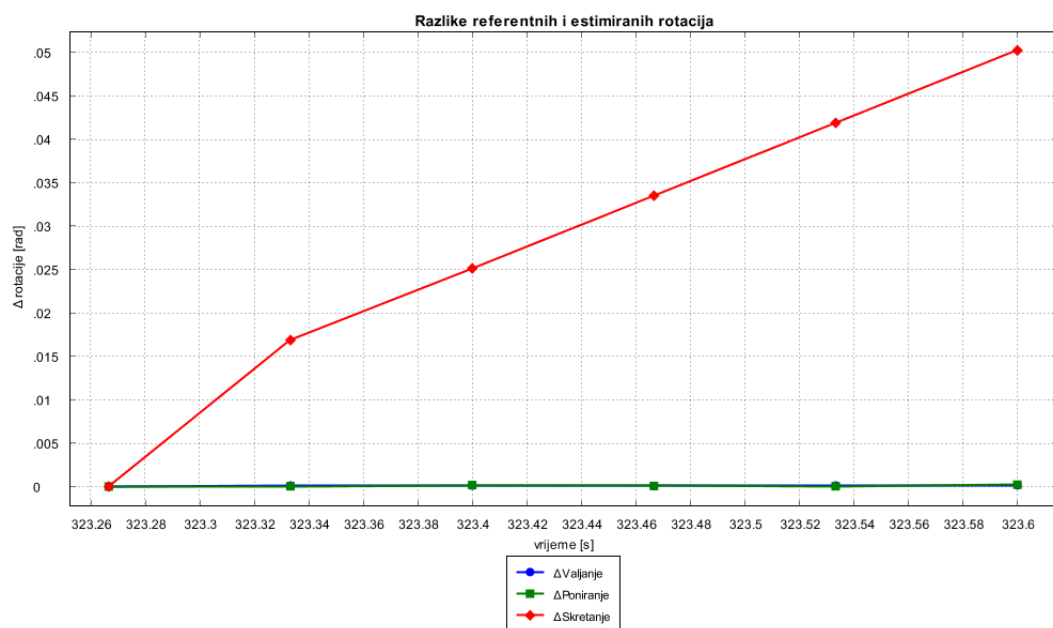
Slika 6.1: Primjer 1 - Graf usporedbe lokacija vozila




Slika 6.2: Primjer 1 - Graf usporedbe rotacija vozila



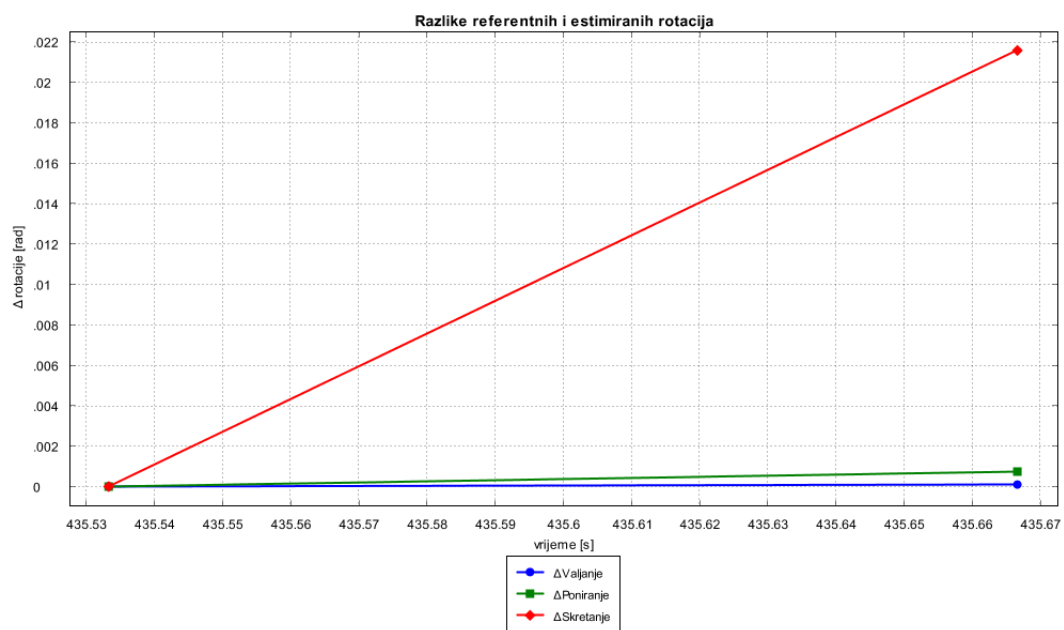
Slika 6.3: Primjer 2 - Graf usporedbe lokacija vozila



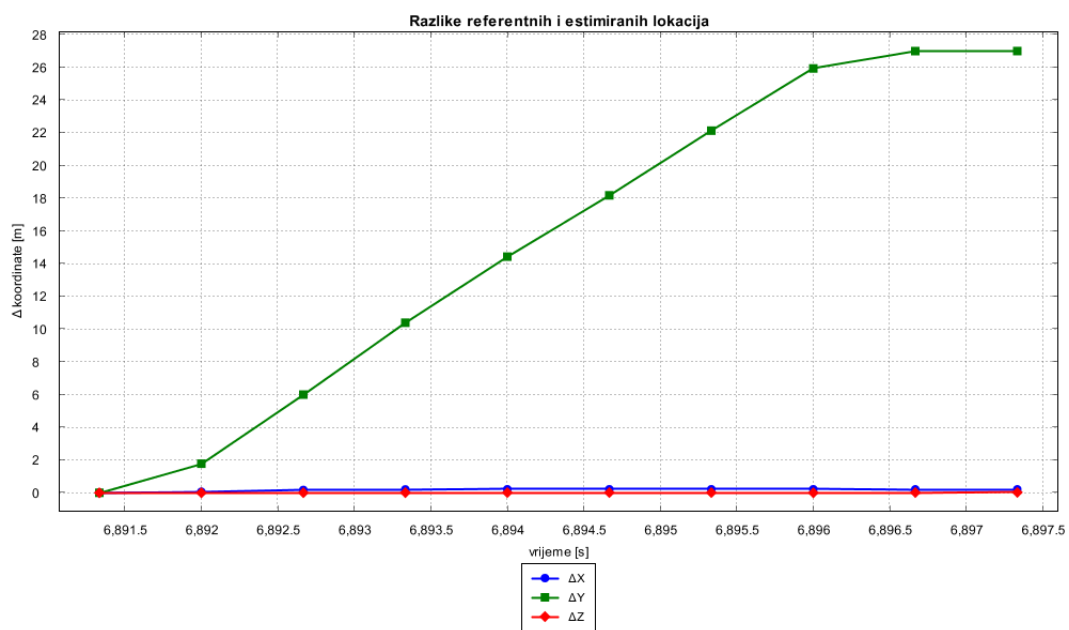
Slika 6.4: Primjer 2 - Graf usporedbe rotacija vozila



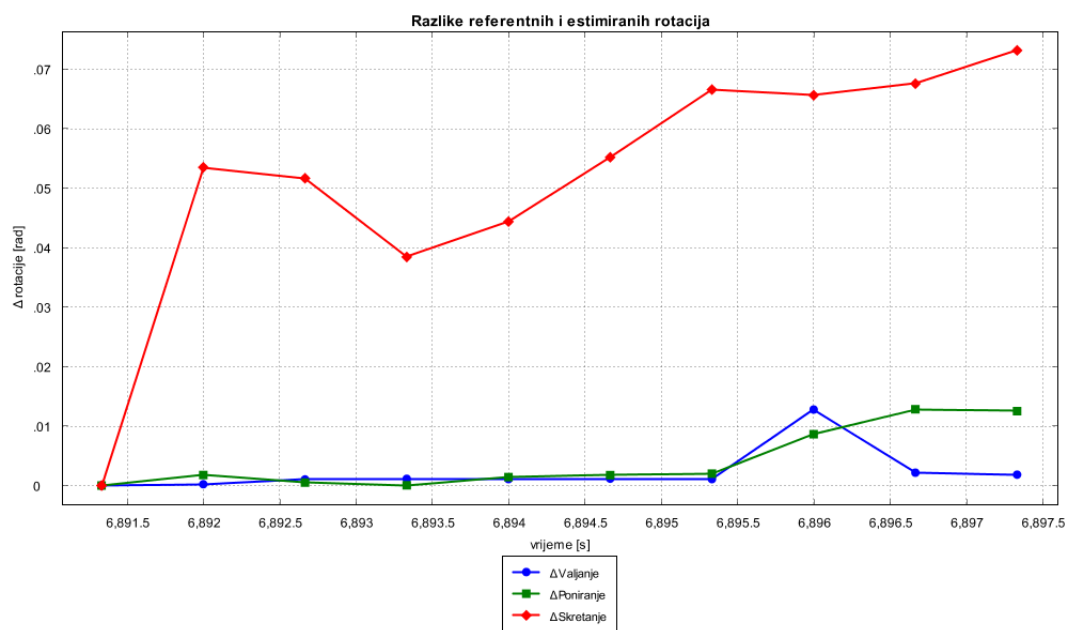
Slika 6.5: Primjer 3 - Graf usporedbe lokacija vozila




Slika 6.6: Primjer 3 - Graf usporedbe rotacija vozila




Slika 6.7: Primjer 4 - Graf usporedbe lokacija vozila




Slika 6.8: Primjer 4 - Graf usporedbe rotacija vozila




Slika 6.9: Primjer 5 - Graf usporedbe lokacija vozila



Slika 6.10: Primjer 5 - Graf usporedbe rotacija vozila



Slika 6.11: Primjer 6 - Graf usporedbe lokacija vozila



Slika 6.12: Primjer 6 - Graf usporedbe rotacija vozila

6.2. ICP algoritam s grupiranjem točaka


Eksperimentalni rezultati za ICP algoritam s grupiranjem točaka su prikazani u sljedećim tablicama i grafovima. Grafovi i tablice se odnose na podskupove točaka primjera A i B. Uspoređivanjem tablica i grafova može se vidjeti da ICP algoritam s grupiranjem točaka uglavnom bolje estimira rotacije, a nekada i lokacije naspram običnoga generalizirajućeg ICP algoritma.

Tablica eksperimentalnih rezultata

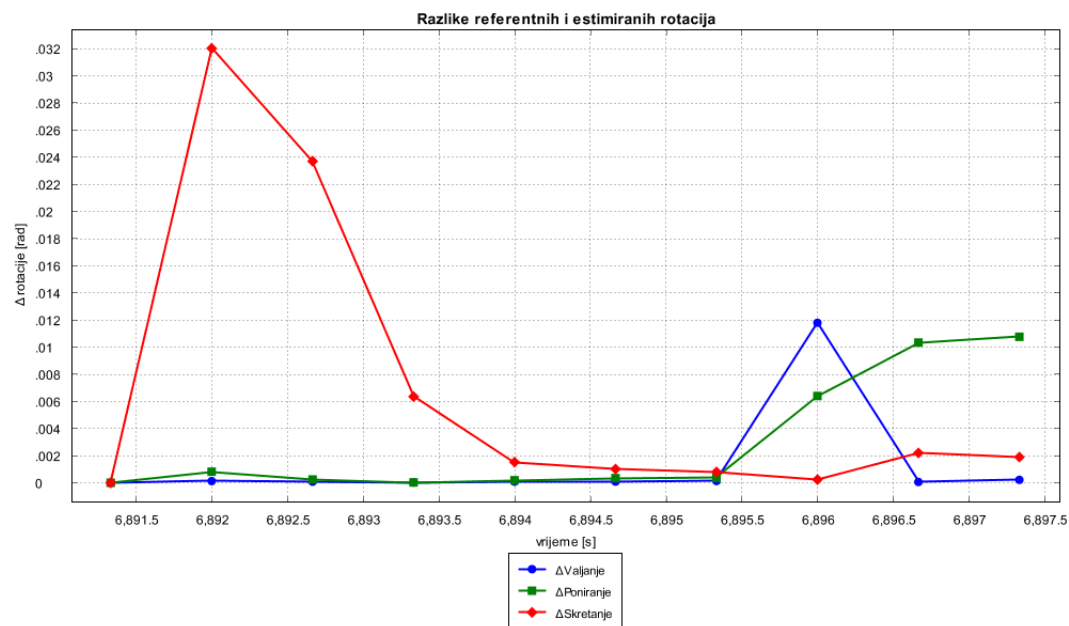
Rezultati	Primjer 1	Primjer 2	Primjer 3	Primjer 4
AMx [m]	0.18283	1.294772	4.58685E-4	0.18752
AMy [m]	15.2912	6.7612E-3	3.4089E-4	16.36098
AMz [m]	2.06568E-2	3.42104E-3	1.18857E-3	0.017125
AMr [rad]	1.25836E-3	2.11339E-4	8.59544E-5	1.14017E-3
AMp [rad]	2.94473E-3	2.86964E-4	4.90207E-5	3.60941E-3
AMy [rad]	6.972636e-3	2.5872e-3	2.614223e-4	6.90612E-3
MSEx [m^2]	3.94724E-2	4.90112	4.20784E-7	4.09558E-2
MSEy [m^2]	330.869234	6.24971E-5	2.32425E-7	367.24570
MSEz [m^2]	6.77314E-4	4.62250E-5	2.82541E-6	3.46930E-4
MSEr [rad^2]	1.39011E-5	6.25045E-8	1.477634-8	1.25063E-5
MSEp [rad^2]	2.64382E-5	1.29621E-7	4.80606E-9	3.19971E-5
MSEy [rad^2]	1.63954E-4	16.25243	1.36683E-7	1.56561E-4

Tablica 6.2: Usporedbe referentnih i estimiranih podataka

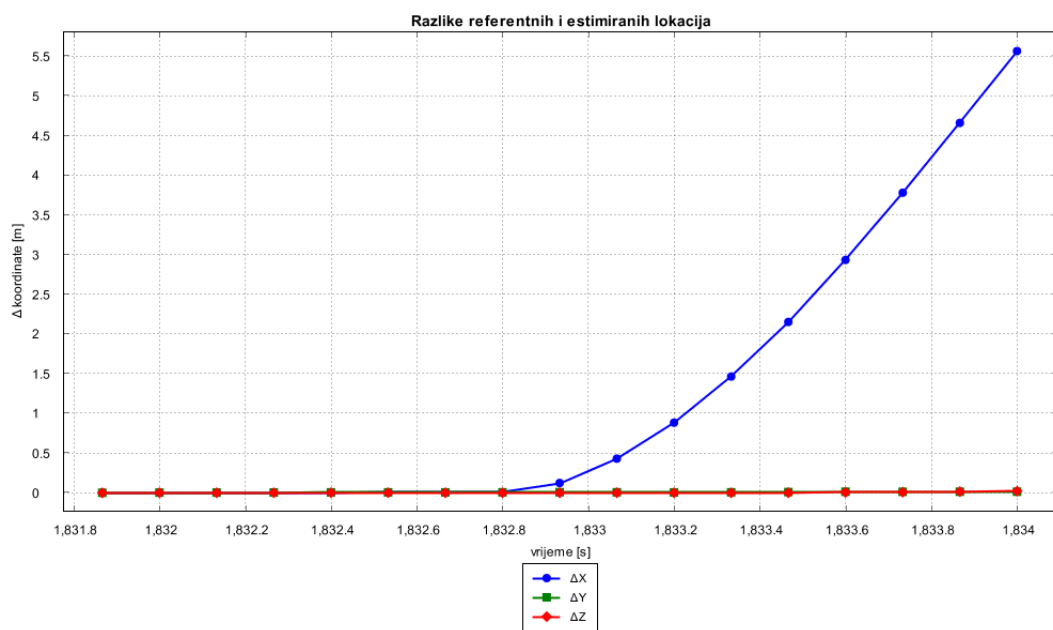
Grafovi eksperimentalnih rezultata



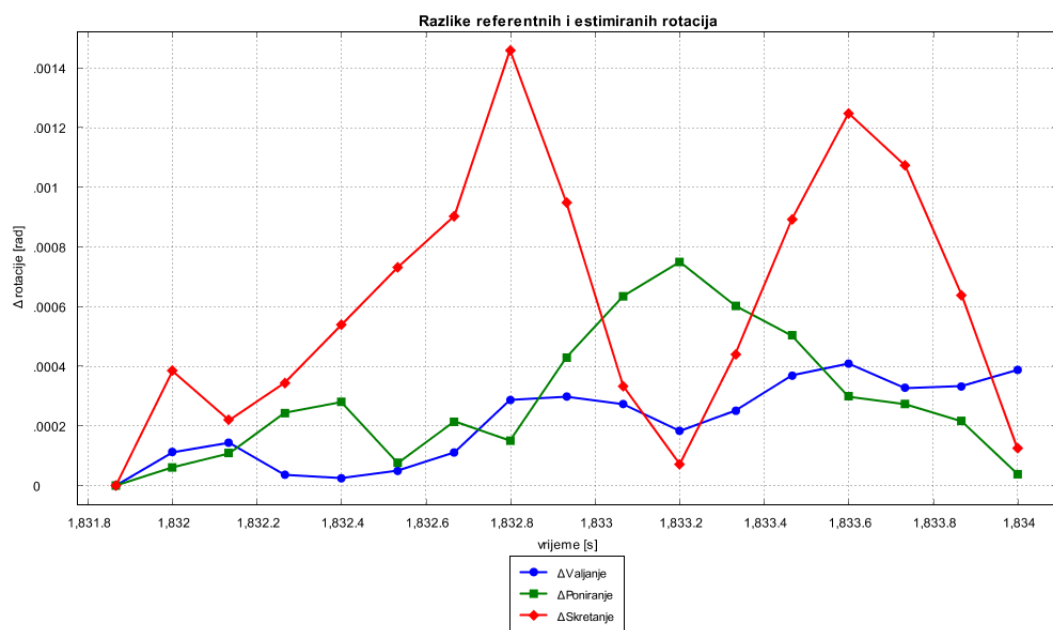
Slika 6.13: Primjer 1 - Graf usporedbe lokacija vozila




Slika 6.14: Primjer 1 - Graf usporedbe rotacija vozila




Slika 6.15: Primjer 2 - Graf usporedbe lokacija vozila




Slika 6.16: Primjer 2 - Graf usporedbe rotacija vozila




Slika 6.17: Primjer 3 - Graf usporedbe lokacija vozila



Slika 6.18: Primjer 3 - Graf usporedbe rotacija vozila



Slika 6.19: Primjer 4 - Graf usporedbe lokacija vozila



Slika 6.20: Primjer 4 - Graf usporedbe rotacija vozila

7. Zaključak

Prilikom lokalizacije vozila ili robota točnost podataka je vrlo važna. Koriste se podaci iz senzora, najčešće LIDAR-a da bi se odredio relativan položaj vozila. Ti podaci se prikazuju kao skupovi točaka. Ti podaci su vrlo jednostavni te ih je zato vrlo lako obrađivati u računalu. Oni se obrađuju raznim algoritmima, ali ti algoritmi ne mogu biti u potpunosti točni. Točnost algoritama može biti promjenjena zbog okoline u kojoj se vozilo nalazi, šuma u očitanjima, broju reprezentativnih podataka u očitaju, samih grešaka u fizičkoj izvedbi senzora ili zbog načina na koji sam algoritam radi. Za evaluaciju točnosti algoritama za različite tipove skupova točaka se koristi simulator kao izvor referentnih podataka. U ovome radu su evaluirani generalizirajući ICP algoritam i ICP s grupiranjem točaka na podskupovima oblaka točaka referentnih lokacija. Rezultati su prikazani s grafovima te podacima o relativnoj i srednjoj pogrešci. Zbog same prirode simulatora, referentni podaci su garantirano točni te to omogućuje testiranje i drugih algoritama koji koriste senzore osim lasera.

LITERATURA

- [1] Auawise. Aircraft principal axes — Wikipedia, the free encyclopedia, 2019. URL <http://en.wikipedia.org/w/index.php?title=Aircraft%20principal%20axes&oldid=893800101>. [Online; June 27, 2019].
- [2] P. J. Besl i N. D. McKay. A method for registration of 3-d shapes. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 14(2):239–256, Feb 1992. ISSN 0162-8828. doi: 10.1109/34.121791.
- [3] Dorit Borrmann, Helge Lauterbach, Sven Jörissen, i Marija Sedar. Oblak točaka katedrale u zagrebu. URL http://kos.informatik.uni-osnabrueck.de/3Dscans/zagreb_square.jpg. [Online; accessed June 27, 2019].
- [4] Carla team. Carla logo. URL <http://carla.org//img/logo/carla-black-m.png>. [Online; accessed June 27, 2019].
- [5] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, i Vladlen Koltun. CARLA: An open urban driving simulator. U *Proceedings of the 1st Annual Conference on Robot Learning*, stranice 1–16, 2017.
- [6] Various open source. Point cloud library. URL <https://www.boost.org/>.
- [7] pointclouds.org. Pointclouds library logo, 2012. URL http://pointclouds.org/assets/images/contents/logos/pcl/pcl_vert_large_pos.png. [Online; June 27, 2019].
- [8] pointclouds.org. Voxelgrid, 2019. URL http://pointclouds.org/documentation/tutorials/voxel_grid.php. [Online; accessed 30-June-2019].
- [9] Rene Rivera. Boost. URL <https://www.boost.org/>.

- [10] Apollo team. Apollo logo, . URL https://github.com/ApolloAuto/apollo/blob/master/docs/demo_guide/images/Apollo_logo.png. [Online; accessed June 27, 2019].
- [11] AVSimulation team. Apollo logo, . URL https://www.avsimulation.fr/wp-content/uploads/2018/07/avsimulation_logo_couleurs_flat.jpg. [Online; accessed June 27, 2019].
- [12] Carla team. Carla logo, . URL https://carla.readthedocs.io/en/latest/cameras_and_sensors/. [Online; accessed June 27, 2019].
- [13] RFPro team. Rfpro logo, . URL <http://www.rfpro.com/wp-content/uploads/logo.svg>. [Online; accessed June 27, 2019].
- [14] Unknown. Arhitektura velodyne lidar uređaja. URL <https://www.renishaw.com/media/img/en/d5f2c0bc53c2419d850b1b979662efe5.jpg>. [Online; accessed June 27, 2019].
- [15] Wikipedia. Centroid — Wikipedia, the free encyclopedia. <http://en.wikipedia.org/w/index.php?title=Centroid&oldid=902707668>, 2019. [Online; accessed 30-June-2019].
- [16] Wikipedia. Iterative closest point — Wikipedia, the free encyclopedia, 2019. URL <http://en.wikipedia.org/w/index.php?title=Iterative%20closest%20point&oldid=883902437>. [Online; accessed 30-June-2019].
- [17] Wikipedia. Quaternion — Wikipedia, the free encyclopedia, 2019. URL <http://en.wikipedia.org/w/index.php?title=Quaternion&oldid=902089865>. [Online; accessed 30-June-2019].
- [18] Wikipedia. Rotation matrix — Wikipedia, the free encyclopedia, 2019. URL <http://en.wikipedia.org/w/index.php?title=Rotation%20matrix&oldid=902636794>. [Online; accessed 30-June-2019].

Lokalizacija autonomnog vozila u simuliranom urbanom okruženju

Sažetak

Postoje razni algoritmi za lokalizaciju vozila pomoću senzorskih očitavanja. S obzirom da ne postoji savršen algoritam rezultati odstupaju od stvarnih vrijednosti. Koristeći simulator sa referentnim podacima možemo jednostavno usporediti stvarne podatke s rezultatima algoritama. Evaluiraju se generalizirajući algoritam iteracije najbliže točke te također taj isti algoritam ali s prijašnjim filtriranjem podataka. Rezultati su prikazani grafovima razlika koordinata i rotacija na poskupovima referentnih podataka. Također su izračunate srednje pogreške i prikazane tablično zbog jednostavnije usporedbe. Predstavljen je specifičan način evaluaciju algoritama korištenjem simulatora, ali čiji se koraci mogu općenito primjeniti na druge izvore podataka i druge algoritme.

Ključne riječi: simulacija; lokalizacija; iteracija najbližih točaka; Carla; evaluacija; PCL; oblak točaka

Autonomous vehicle localization in a simulated urban environment

Abstract

There are various vehicle location algorithms using sensory readings. Since there is no perfect algorithm the results deviate from the actual values. Using a simulator with reference data, we can easily compare actual data with algorithm results. Evaluated algorithms are generalized iterative closest point and previous algorithm but with the previous data filtering. The results are shown using graphs of the coordinate differences and rotation differences between estimated values and referent values. Mean errors were also calculated and displayed in the table. A specific way of evaluating algorithms using a simulator was presented but whose steps generally be applied to other data sources and other algorithms.

Keywords: simulation; localization; iterative closest point; Carla; evaluation; PCL; point cloud